Wirtualna i rozszerzona rzeczywistość

Wykład 4

Śledzenie i rozumienie sceny

dr inż. Mateusz Pomianek

Automatyka i Robotyka, studia II stopnia, 3 ECTS

Katedra Informatyki i Automatyki

Rok akademicki 2026/2027

Wersja 2.1.2 14.10.2026

Cel wykładu i przebieg

Po wykładzie można:

- obliczyć błąd prostego modelu IMU;
- rozróżnić VIO, SLAM i relokalizację;
- dobrać kotwicę i czujnik głębi;
- obliczyć głębię i punkt 3D z piksela;
- wyjaśnić okluzję i rolę segmentacji;
- zdiagnozować błąd rejestracji AR.

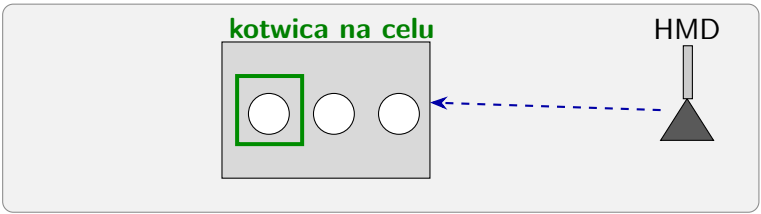
Plan: około 90 min

0–40 min: śledzenie, mapa, kotwice

40–50 min: przerwa

50–90 min: głębia, scena, diagnoza

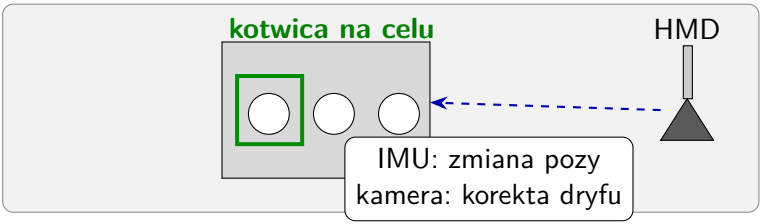
Kamera i IMU utrzymują nakładkę na panelu



Co można odtworzyć

Śledź jedną wskazówkę nad elementem panelu; ogranicz obserwacje kamery i porównaj stan śledzenia z położeniem nakładki.

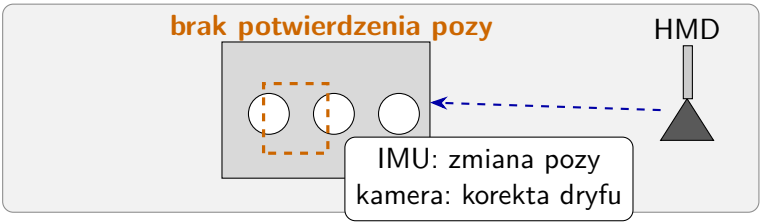
Kamera i IMU utrzymują nakładkę na panelu



Co można odtworzyć

Śledź jedną wskazówkę nad elementem panelu; ogranicz obserwacje kamery i porównaj stan śledzenia z położeniem nakładki.

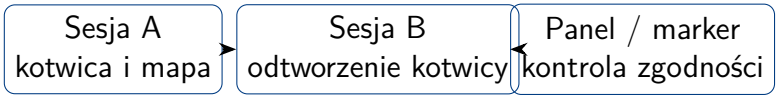
Kamera i IMU utrzymują nakładkę na panelu



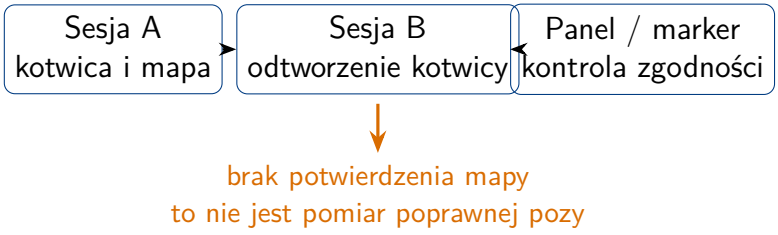
Co można odtworzyć

Śledź jedną wskazówkę nad elementem panelu; ogranicz obserwacje kamery i porównaj stan śledzenia z położeniem nakładki.

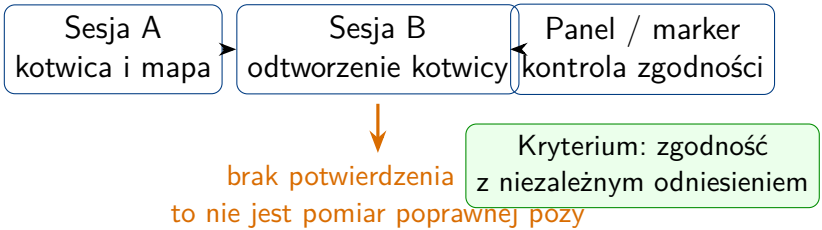
Płynny obraz nie dowodzi poprawnej relokalizacji



Płynny obraz nie dowodzi poprawnej relokalizacji



Płynny obraz nie dowodzi poprawnej relokalizacji



IMU: prędkość kątowa i siła właściwa

IMU: inercyjna jednostka pomiarowa (*inertial measurement unit*).

$$\boldsymbol{\omega}_m = \boldsymbol{\omega} + \mathbf{b}_g + \mathbf{n}_g, \qquad \mathbf{f}_m = R^{\mathsf{T}}(\mathbf{a} - \mathbf{g}) + \mathbf{b}_a + \mathbf{n}_a$$

- Żyroskop mierzy prędkość kątową. Akcelerometr mierzy siłę właściwą.
- W spoczynku $\|\mathbf{f}\| \approx g$; w swobodnym spadku $\mathbf{f} \approx 0$.
- Grawitacja wspiera ocenę przechyłu przy małych przyspieszeniach ruchu.
- Magnetometr może wspierać kurs, lecz stal i silniki zakłócają pomiar.

R: obrót z układu IMU do świata; $\mathbf{a}$: przyspieszenie w świecie; $\mathbf{b}$: bias; $\mathbf{n}$: szum.

Źródło: [1], [2].

Stały bias akumuluje się podczas całkowania

Bias żyroskopu

$$\delta\theta(t) = b_g t$$

Dla $b_g = 0{,}1^\circ/\mathrm{s}$:

2 s: $0{,}2^\circ$
10 s: 1°
60 s: 6°

Bias akcelerometru

$$\delta p(t) = \tfrac{1}{2} b_a t^2$$

Dla $b_a = 0{,}01\ \mathrm{m/s^2}$:

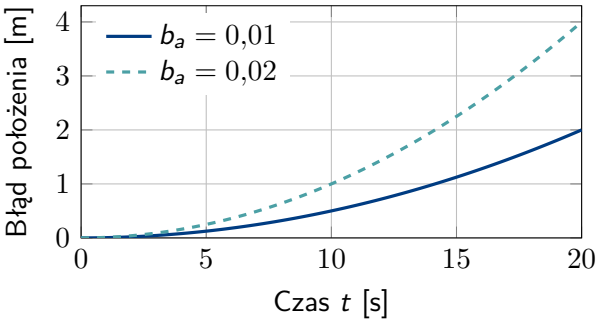
2 s: 2 cm
10 s: 0,5 m
60 s: 18 m

Modele zakładają stały bias, poprawną orientację i brak korekt.

Model ilustracyjny, nie pomiar konkretnego urządzenia.

Źródło: [1], [2].

Dryf położenia: jawny model i jednostki



Model ilustracyjny, nie pomiar konkretnego urządzenia.

Źródło: [1].

Dwa stałe biasy

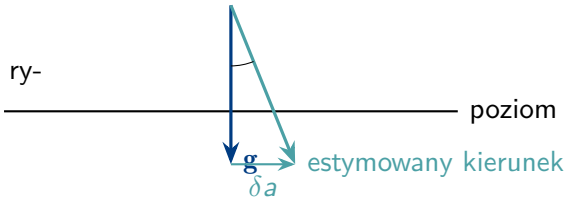
$0{,}01\,\mathrm{m/s^2}$
$0{,}02\,\mathrm{m/s^2}$

Przy 20 s:
2 m oraz 4 m.

Korekta wizyjna może ograniczać błąd. Jej wynik zależy od sceny i estymatora.

Mały błąd przechyłu daje fałszywe przyspieszenie

Błąd przechyłu
$\delta\theta = 0{,}1^\circ$
kąt powiększony na rysunku



$$\delta a = g \sin(0{,}1^\circ) \approx 0{,}0171\,\mathrm{m/s^2}$$

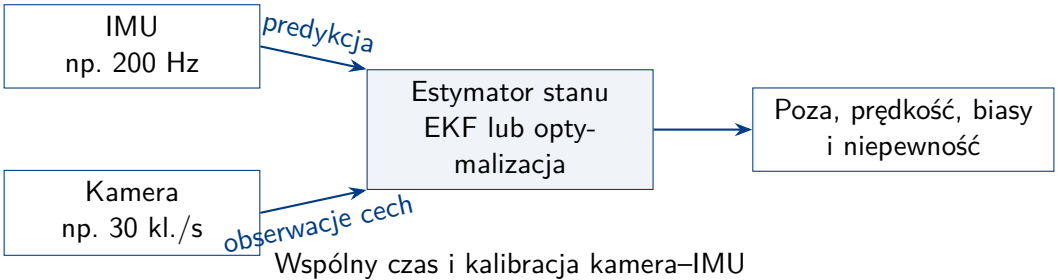
Czas	2 s	10 s	60 s
$\frac{1}{2}\delta a\, t^2$	3,4 cm	0,86 m	30,8 m

Model ilustracyjny, nie pomiar konkretnego urządzenia.

Źródło: [1], [2].

Fuzja kamera–IMU: uzupełniające się pomiary

VIO: odometria wizyjno-inercyjna (*visual-inertial odometry*).



IMU wspiera predykcję. Obserwacje wizualne korygują stan i biasy.

Źródło: [2]–[4].

Obserwowalność i kalibracja VIO

- Monokularna odometria wizyjna nie określa bezwzględnej skali.
- IMU wspiera skalę metryczną przy odpowiednim pobudzeniu ruchowym.
- Bez odniesień zewnętrznych globalna pozycja i obrót wokół pionu pozostają nieobserwowalne.
- Kalibracja obejmuje parametry kamery, transformację kamera–IMU oraz przesunięcie czasowe.

Płynna trajektoria może dryfować względem hali.

Źródło: [2], [3], [5], [6].

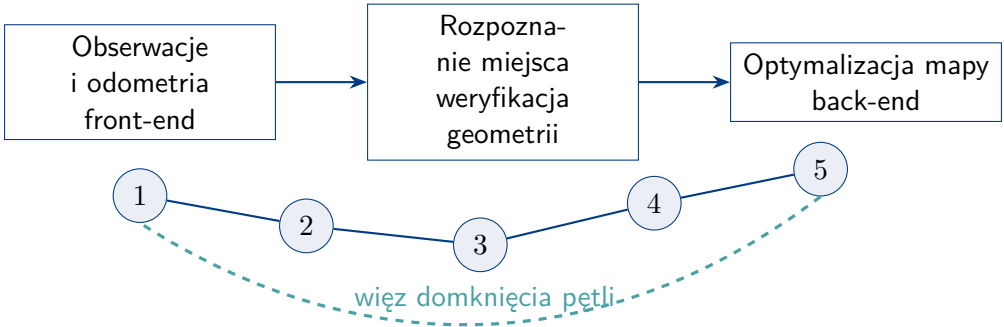
VIO i SLAM: ruch lokalny oraz spójność mapy

SLAM: jednoczesna lokalizacja i mapowanie.

	VIO	SLAM
Cel	Estymacja ruchu	Estymacja pozy i mapy
Dane	Kamera i IMU	Kamera lub skaner laserowy
Korekta	Lokalne obserwacje	Także więzy między miejscami
Dryf	Możliwy w długim ruchu	Może maleć po domknięciu pętli
Po restarcie	Układ lokalny	Mapa pomaga, jeśli ją zapisano i dopasowano

Źródło: [7], [8].

SLAM: domknięcie pętli (loop closure)



Węzły: pozy klatek kluczowych. Krawędzie: pomiary względne.

Ponowna obserwacja miejsca dodaje więz między odległymi chwilami.
Fałszywy więz może zniekształcić mapę.

Źródło: [7], [8].

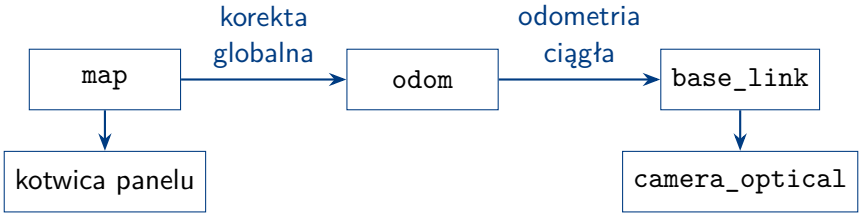
Domknięcie pętli, relokalizacja i lokalizacja globalna

Operacja	Sytuacja	Wynik
Domknięcie pętli	Powrót do znanego obszaru	Dodatkowy więz i korekta mapy
Relokalizacja	Utrata pozy lub nowa sesja	Poza względem istniejącej mapy
Lokalizacja globalna	Brak użytecznego przybliżenia pozy	Przeszukanie szerszego zbioru hipotez

Globalna lokalizacja może być sposobem realizacji relokalizacji.

Źródło: [7], [8].

Układy ROS: mapa, odometria i urządzenie

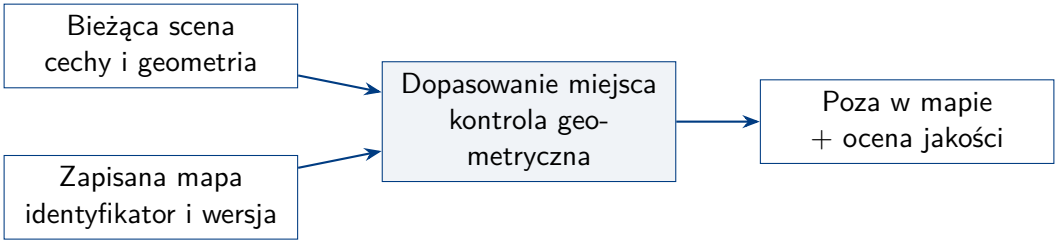


$$^{map}T_{body} = {}^{map}T_{odom}\,{}^{odom}T_{body}$$

- `odom`: ciągły ruch lokalny, możliwy dryf.
- `map`: odniesienie globalne, korekta może powodować skok pozy.
- Nowa sesja potrzebuje powiązania z mapą.

Źródło: [9].

Relokalizacja wymaga zgodnej mapy i obserwacji

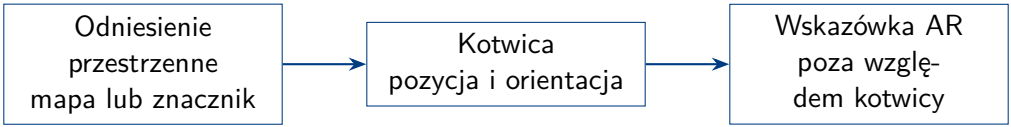


Płynność lokalnego śledzenia i poprawność dopasowania mapy to osobne kryteria.

Błędy sprawdzam względem niezależnego punktu odniesienia.

Źródło: [7], [8].

Kotwica: poza i warunki odtworzenia

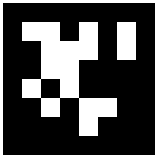


Odtworzenie: zapis ID i danych odniesienia, dopasowanie, weryfikacja

- Kotwica określa pozę 6-DoF powiązaną z odniesieniem przestrzennym.
- Zapis współrzędnych wymaga identyfikatora i odzyskania właściwego układu.
- ARCore rozróżnia kotwice lokalne, Cloud i Geospatial.

Źródło: [9], [10].

Marker daje lokalne odniesienie przy panelu



AprilTag 36h11, ID 0

Znany rozmiar + kalibracja + narożniki: estymacja pozy.

$$\sigma_X \approx \frac{Z\sigma_u}{f} = \frac{1\,\mathrm{m} \cdot 0{,}5\,\mathrm{px}}{615\,\mathrm{px}} \approx 0{,}81\,\mathrm{mm}$$

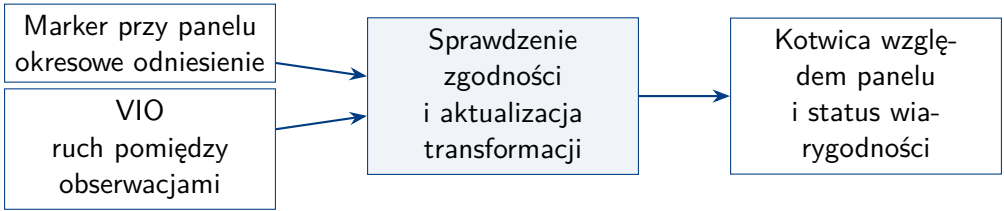
To propagacja błędu pojedynczej współrzędnej obrazu, nie dokładność całej pozy markera.

Ograniczenia: zasłonięcie, rozmiar w obrazie, kąt, kalibracja i dwuznaczność pozy płaskiej.

Źródło: [11], [12].

Model ilustracyjny, nie pomiar konkretnego urządzenia.

Kotwiczenie hybrydowe: marker i odometria

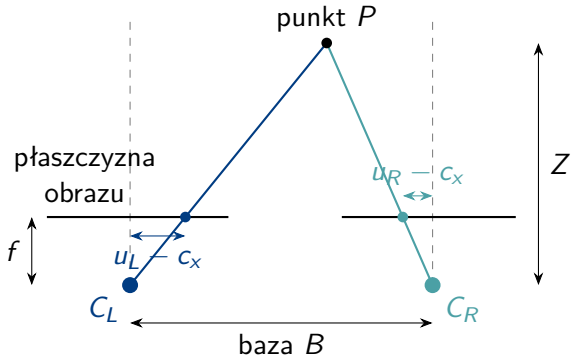


Odniesienie	Wymagania	Trwałość i ograniczenia
Marker	Znacznik przy panelu	Montaż i widoczność
Mapa bez markera	Rozpoznawalna scena	Zgodność mapy z halą
Kotwica chmurowa	Usługa i odtworzenie	API i dopasowanie

Źródło: [9]–[11].

Przerwa 5 min

Stereo: baza i dysparycja określają głębię



$d = u_L - u_R$; $d > 0$ dla punktu przed kamerami

$$Z = \frac{fB}{d}$$

f: ogniskowa [px]

B: baza kamer [m]

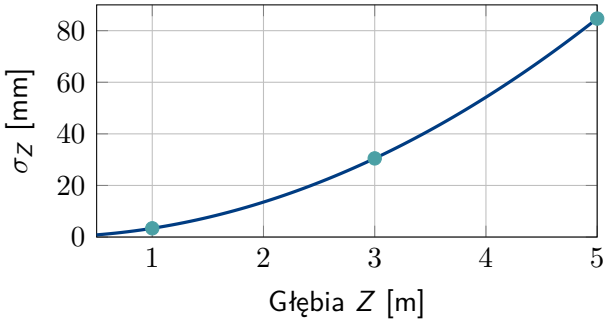
$d = u_L - u_R$: dysparycja [px]

Z: głębia [m]

Wzór zakłada skalibrowaną, rektyfikowaną parę kamer.

Źródło: [12], [13].

Niepewność stereo rośnie z kwadratem głębi



Model ilustracyjny, nie pomiar konkretnego urządzenia.

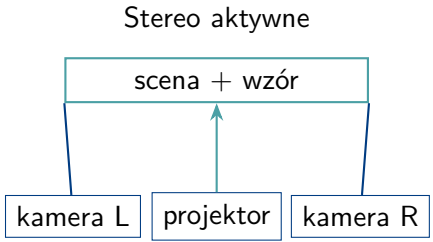
Źródło: [12], [13].

$$\sigma_Z \approx \frac{Z^2 \sigma_d}{fB}$$

$f = 615$ px
$B = 0{,}12$ m
$\sigma_d = 0{,}25$ px

1 m: 3,4 mm
3 m: 3,0 cm
5 m: 8,5 cm

Stereo aktywne i światło strukturalne

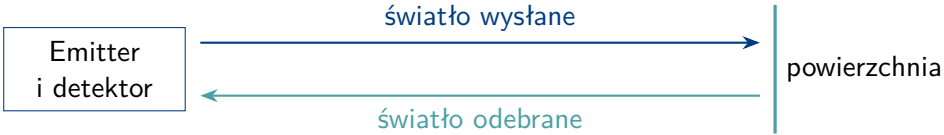


- Stereo pasywne dopasowuje naturalną teksturę między kamerami.
- Stereo aktywne dodaje teksturę, ale nadal dopasowuje dwa obrazy.
- Światło strukturalne trianguluje względem znanego wzoru projektora.

Źródło: [14], [15].

ToF: czas impulsu lub przesunięcie fazy

ToF: czas przelotu światła (*time of flight*).



Droga tam i z powrotem: $2R$

dToF: impuls $R = c\Delta t/2$
20 ns: około 3 m.
1 ns różnicy: około 15 cm.

iToF: faza $R = c\phi/(4\pi f_m)$
Dla jednej częstotliwości:
$R_{jedn} = c/(2f_m)$; 20 MHz: 7,5 m.

LiDAR (light detection and ranging): laserowy pomiar odległości, m.in. ToF i FMCW.

Źródło: [16]–[18].

Parametry czujnika zawsze dotyczą określonego trybu

	RealSense D455	ST VL53L5CX
Zasięg	Zalecany: 0,6–6 m	Do 4 m, zależnie od warunków
Głębia	Do 1280×720	4×4 lub 8×8 stref
Częstotliwość	Do 90 kl./s, zależnie od trybu	4×4: do 60 Hz; 8×8: do 15 Hz
Błąd	Producent: $< 2\%$ przy 4 m	W ciemności: $\pm 5\%$ przy 8×8, 15 Hz, 201–4000 mm*

*Cel 88%, całe pole widzenia, 23 °C, kryterium $2{,}7\sigma$. Miary i warunki nie są wspólne dla obu urządzeń. Maksima rozdzielczości i FPS D455 nie muszą występować jednocześnie.

Źródło: [13], [17].

Dobór głębi: trzy objaśnione scenariusze

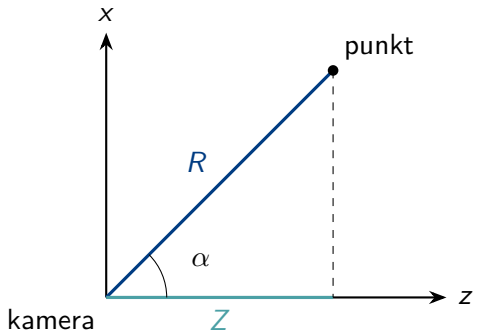
Scena	Wstępny wybór	Warunek sprawdzenia
Ciemny magazyn	Aktywna głębia z oświetleniem IR	Zasięg, materiały, energia i inne emitery
Plac w słońcu	Stereo pasywne, jeśli scena ma teksturę	Światło, ruch, kompletność i koszt obliczeń
Dłoń w odległości 0,3 m	Czujnik bliskiego zasięgu z gęstą mapą	Minimalny dystans, FPS, krawędzie i energia

D455 przy maksymalnej rozdzielczości ma Min-Z około 0,52 m.

Dla ToF sprawdzam wielotorowość, krawędzie, szkło, ciemne cele oraz światło otoczenia.

Źródło: [13], [16], [17].

Głębia osiowa Z i odległość radialna R



$$R = \sqrt{X^2 + Y^2 + Z^2}$$

$$Z = R \cos \alpha$$

Dla $\alpha = 45°$:
$R/Z = \sqrt{2} \approx 1{,}414.$

Podstawienie R w miejsce Z zawyża skalę o 41,4%.

Format i jednostkę ustala dokumentacja strumienia, nie nazwa technologii.

Źródło: [16], [19].

Deprojekcja: piksel staje się punktem 3D

Dla obrazu rektyfikowanego i głębi osiowej w metrach:

$$X = \frac{(u - c_x)Z}{f_x}, \qquad Y = \frac{(v - c_y)Z}{f_y}, \qquad Z = Z$$

Dane

$(u, v) = (410, 260)$ px
$(c_x, c_y) = (320, 240)$ px
$f_x = f_y = 615$ px
$Z = 1{,}35$ m

Wynik

$X \approx 0{,}198$ m
$Y \approx 0{,}044$ m
$R \approx 1{,}365$ m

ROS optical: x w prawo, y w dół, z do przodu.

Model ilustracyjny, nie pomiar konkretnego urządzenia.

Źródło: [12], [19], [20].

Kod deprojekcji: jawne założenia wejścia

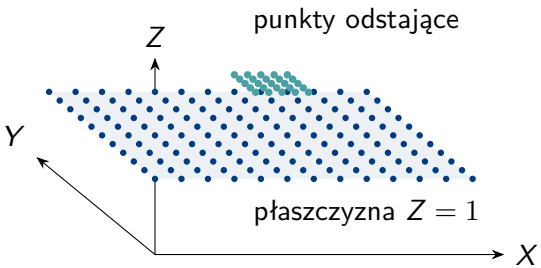
```
łęąąęą
def deproject(u, v, z, fx, fy, cx, cy):
    if not all(isfinite(a) for a in (u, v, z, fx, fy, cx, cy)):
        raise ValueError("Dane ąmusz ćby ńskoczone")
    if z <= 0 or fx <= 0 or fy <= 0:
        raise ValueError("Z oraz ogniskowe ąmusz ćby dodatnie")
    x = (u - cx) * z / fx
    y = (v - cy) * z / fy
    return x, y, z
```

- Rektyfikowany piksel, dodatnie Z w metrach, ogniskowe w pikselach.
- Obraz: maska wartości nieważnych i jawna konwersja mm do m.
- Surowe piksele: `undistortPoints`; wynik to znormalizowany promień.

Źródło: [12], [19].

Chmura punktów i płaszczyzna RANSAC

RGB-D: obraz barwny wraz z głębią (*red, green, blue, depth*).



$$aX + bY + cZ + d = 0$$

RANSAC szuka modelu wspieranego przez wiele punktów.

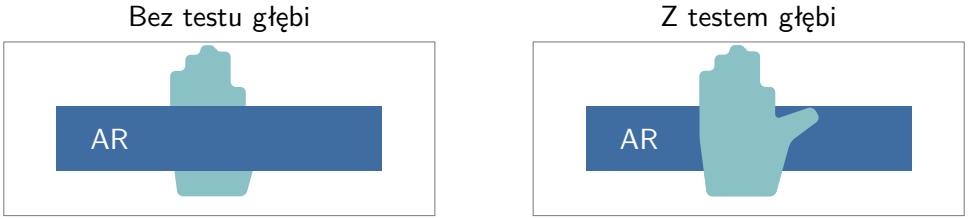
Open3D: `segment_plane`
Próg 0,01 m: odległość punktu od płaszczyzny, nie od kamery.

Płaszczyzna opisuje geometrię. Nazwa „stół” wymaga dodatkowej interpretacji.

Model ilustracyjny, nie pomiar konkretnego urządzenia.

Źródło: [21].

Okluzja: test głębi w tym samym pikselu



Realna dłoń: $Z_{real} = 0{,}5$ m. Wirtualny panel: $Z_{virt} = 1{,}2$ m.

rysuję piksel wirtualny, gdy $Z_{virt}(u, v) < Z_{real}(u, v)$

Obie głębie muszą odnosić się do tej samej kamery, chwili i jednostki.
Brak pomiaru oznacza nieznaną geometrię. Potrzebna jest jawna polityka obsługi.

Źródło: [19], [22].

Okluzja zależy także od obrazu i czasu

OST: przezierność optyczna

Światło realne trafia bezpośrednio do oka.

Typowy wyświetlacz dodaje światło. Pełne zasłonięcie świata wymaga dodatkowego mechanizmu blokowania.

VST: przezierność wideo

Kamera dostarcza obraz świata do kompozycji.

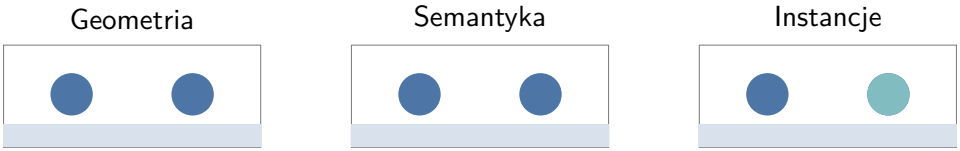
Możliwa kontrola obu warstw, kosztem opóźnienia i jakości obrazu świata.

Siatka statyczna opisuje halę. Aktualna głębia może opisać poruszającą się dłoń.

Niedopasowanie czasu i rozdzielczości daje obwódki oraz migotanie. Reprojekcja pomaga dopasować widok, ale nie odtwarza niezmierzonego ruchu.

Źródło: [22], [23].

Segmentacja: geometria, klasa i instancja

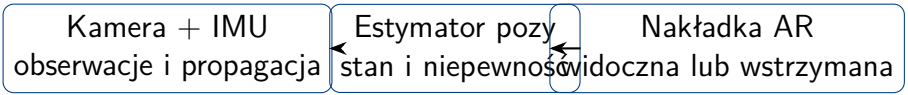


- Semantyczna: klasa każdego piksela lub punktu.
- Instancyjna: oddzielne obiekty tej samej klasy.
- Panoptyczna: wspólna reprezentacja klas i instancji.

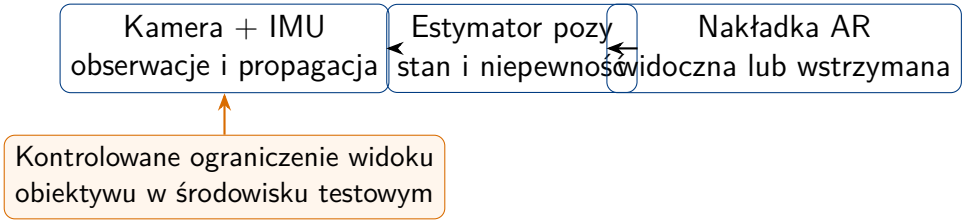
Mask R-CNN: klasy i maski instancji. SAM: maski, bez automatycznej nazwy klasy.

Źródło: [21], [24], [25].

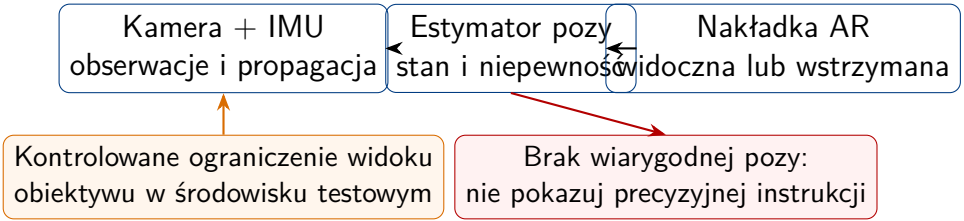
Utrata obserwacji: nakładka musi sygnalizować jakość



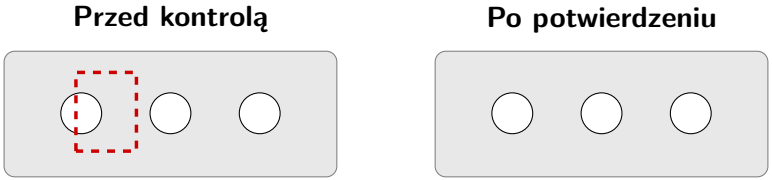
Utrata obserwacji: nakładka musi sygnalizować jakość



Utrata obserwacji: nakładka musi sygnalizować jakość



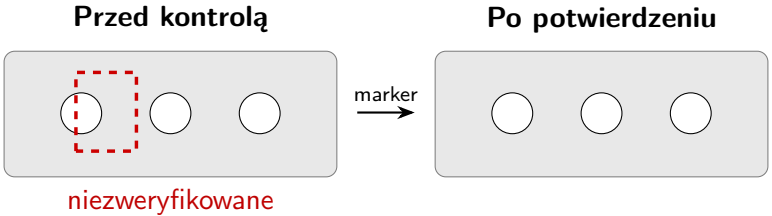
Odtwarzanie kotwicy: sprawdzenie na tym samym panelu



Dwa osobne warunki

Śledzenie lokalne pozostaje stabilne **oraz** odtworzona kotwica pokrywa fizyczny punkt odniesienia w granicach tolerancji zadania.

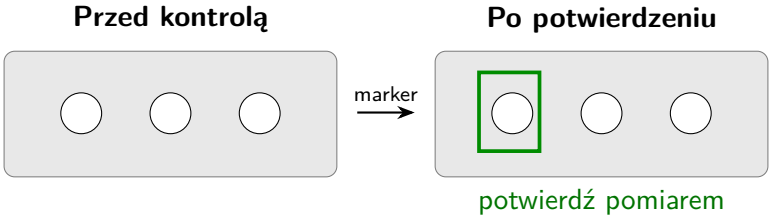
Odtwarzanie kotwicy: sprawdzenie na tym samym panelu



Dwa osobne warunki

Śledzenie lokalne pozostaje stabilne **oraz** odtworzona kotwica pokrywa fizyczny punkt odniesienia w granicach tolerancji zadania.

Odtwarzanie kotwicy: sprawdzenie na tym samym panelu

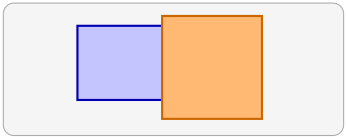


Dwa osobne warunki

Śledzenie lokalne pozostaje stabilne **oraz** odtworzona kotwica pokrywa fizyczny punkt odniesienia w granicach tolerancji zadania.

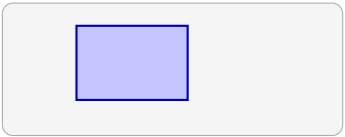
Okluzja: prawdziwy obiekt ma zasłaniać wirtualny

Brak informacji o głębi



warstwy rysowane
bez testu głębokości

Poprawna okluzja



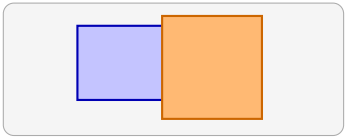
przedni obiekt fizyczny
przesłania fragment treści AR

Mechanizm

Porównaj głębię obiektu fizycznego i wirtualnego w tym samym pikselu oraz zgodnym czasie pomiaru.

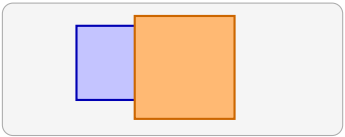
Okluzja: prawdziwy obiekt ma zasłaniać wirtualny

Brak informacji o głębi



warstwy rysowane
bez testu głębokości

Poprawna okluzja



przedni obiekt fizyczny
przesłania fragment treści AR

Mechanizm

Porównaj głębię obiektu fizycznego i wirtualnego w tym samym pikselu oraz zgodnym czasie pomiaru.

Kod Python: ukryj niewiarygodną nakładkę AR

```
1
2  def allow_overlay(tracked, anchor_verified, uncertainty_m,
       limit_m):
3      return (
4          tracked
5          and anchor_verified
6          and isfinite(uncertainty_m)
7          and isfinite(limit_m)
8          and limit_m > 0
9          and 0 <= uncertainty_m <= limit_m
10     )
```

Cztery warunki
Śledzenie poprawne, kotwica sprawdzona, niepewność skończona, błąd mieści się w tolerancji.

Tolerancja
Granicę błędu wyznaczają wymagania konkretnego zadania.

Zrzut: gdy śledzenie obiektu traci wiarygodność



Miejsce na rzeczywisty zrzut ekranu: Widok AR/passthrough z panelu i wskazówki oraz rzeczywisty status śledzenia/relokalizacji.
Dwa kadry: stan prawidłowy i ograniczenie obserwacji.

Wnioski i przejście do integracji

- IMU przewiduje ruch, a biasy i błędy przechyłu narastają.
- VIO śledzi lokalnie. Mapa i relokalizacja wiążą sesje z miejscem.
- Trwałą kotwicę weryfikuję przy fizycznym odniesieniu.
- Okluzja potrzebuje głębi lub geometrii. Segmentacja opisuje obiekty.
- Jednostki, układy, czas i jakość danych tworzą wspólny kontrakt integracji.

Panel robota: marker + śledzenie + kontrola jakości i wersji mapy.

Przykładowe pytania egzaminacyjne

1. Jakie informacje dostarczają IMU i kamera w VIO oraz co powoduje narastanie błędu estymacji pozy?
2. Jaka jest różnica między lokalnym śledzeniem ruchu, mapowaniem SLAM a relokalizacją?
3. Jak sprawdzić, czy kotwica AR zachowuje pozycję po ponownym uruchomieniu aplikacji?
4. Kiedy do poprawnej okluzji obiektów potrzebna jest mapa głębi, a kiedy wystarcza znana geometria?

Bibliografia: sześć źródeł podstawowych

Śledzenie i geometria

- O. J. Woodman, *An Introduction to Inertial Navigation*, 2007.
- C. Forster i in., *On-Manifold Preintegration for Real-Time Visual-Inertial Odometry*, 2017.
- C. Campos i in., *ORB-SLAM3*, IEEE Transactions on Robotics, 2021.

Głębia i rejestracja

- E. Olson, *AprilTag: A Robust and Flexible Visual Fiducial System*, ICRA, 2011.
- H. Sarbolandi i in., *Kinect Range Sensing: Structured-Light versus Time-of-Flight Kinect*, CVIU, 2015.
- T. Foote i in., *REP-103: Standard Units of Measure and Coordinate Conventions*, ROS.

Pełne metadane i pozostałe źródła: `bibliography.bib` oraz `sources.json` w repozytorium.

Kolejne materiały

← Wykład 3	Laboratorium 4	Wykład 5 →